

This page is under active construction. Expect bugs.

Způsoby popisu rozdělení náhodných veličin a vektorů. Odhady parametrů rozdělení. Základní statistické testy. Markovské řetězce a jejich asymptotické vlastnosti.

B0B01PST [Webové stránky předmětu](#) [Helisova stránky předmětu](#)

- **Definice pravděpodobnosti (Kolmogorovova)** – nezávislost náhodných jevů, podmíněná pravděpodobnost, Bayesova věta. Pojem náhodné veličiny, popis jejího rozdělení pomocí distribuční funkce, hustoty, pravděpodobnostní funkce. Střední hodnota, rozptyl, směrodatná odchylka, momenty náhodných veličin. Základní typy spojitých a diskrétních rozdělení.
- **Náhodné vektory a jejich popis** – nezávislost náhodných veličin, kovariance a korelace.
- **Čebyševova nerovnost** – centrální limitní věta.
- **Základní pojmy statistiky** – náhodný výběr, empirické rozdělení.
- **Obecné vlastnosti odhadů parametrů** – odhady střední hodnoty, rozptylu, směrodatné odchylky, momentů. Odhady parametrů metodou momentů a metodou maximální věrohodnosti. Intervalové odhady.
- **Princip statistického testování hypotéz** – testy střední hodnoty a rozptylu, porovnání dvou rozdělení, χ^2 -test dobré shody, test nezávislosti v kontingenční tabulce.
- **Markovovy řetězce** – základní pojmy a vlastnosti, popis přechodovým diagramem a maticí přechodu. Klasifikace stavů, periodicita, rozložitelnost. Asymptotické chování Markovových řetězců.

1. Definice pravděpodobnosti (Kolmogorovova)

- Definice pravděpodobnosti (Kolmogorovova) – nezávislost náhodných jevů, podmíněná pravděpodobnost, Bayesova věta. Pojem náhodné veličiny, popis jejího rozdělení pomocí distribuční funkce, hustoty, pravděpodobnostní funkce. Střední hodnota, rozptyl, směrodatná odchylka, momenty náhodných veličin. Základní typy spojitých a diskrétních rozdělení.
- Pravděpodobnost je funkce, která popisuje budoucí pravdivost neznámých jevů. Z teorie vyvozujeme realitu – udává, jak moc očekáváme, že nastane určitý jev.
- Náhodný pokus – proces, jehož výsledek není předem jednoznačně určen, ale lze popsat množinou možných výsledků. Např. hod kostkou.
- Elementární jev – konkrétní výsledek náhodného pokusu.
- Jev – množina elementárních jevů, které sdílí určitou vlastnost. Např. „padla sudá“.
- Jistý jev – nastává vždy, nemožný jev – nikdy. Opačný jev – doplněk vzhledem k celku.
- Jevové pole – množina všech pozorovatelných jevů (např. $\exp \Omega$).
- Úplný systém jevů – kolekce navzájem neslučitelných jevů, jejichž sjednocení tvoří jistý jev. Součet jejich pravděpodobností je 1.

Kolmogorovova definice pravděpodobnosti

- Kolmogorovova definice pravděpodobnosti je založená na třech axiomech:
 - **Axiom nezápornosti:** $\forall A \in \mathcal{A} : P(A) \geq 0$
 - **Axiom normovanosti:** $P(\Omega) = 1$
 - **Axiom σ -aditivity:** Pro neslučitelné jevy $A_1, A_2, \dots$, platí:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

- Pravděpodobnostní prostor je trojice $(\Omega, \mathcal{A}, P)$, kde:

- Ω – neprázdná množina elementárních jevů
- $\mathcal{A}$ – σ -algebra podmnožin Ω
- P – pravděpodobnostní míra
- σ -algebra $\mathcal{A}$ splňuje:
 - $\emptyset \in \mathcal{A}$
 - $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$
 - $A_1, A_2, \dots \in \mathcal{A} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$
- Borelova σ -algebra – nejmenší σ -algebra na $\mathbb{R}$ obsahující všechny otevřené intervaly. Obsahuje i uzavřené, polouzavřené a jejich spočetné sjednocení.

Nezávislost náhodných jevů

- Jevy A a B jsou **nezávislé**, pokud:
 - $P(A \cap B) = P(A) \cdot P(B)$
 - To znamená, že výskyt jednoho jevu nijak neovlivňuje výskyt druhého.
 - Ekvivalentně: $P(A|B) = P(A)$ a $P(B|A) = P(B)$
- Důsledky:
 - Pro nezávislé jevy platí také: $P(A \cup B) = P(A) + P(B) - P(A) \cdot P(B)$
- Nezávislost nelze zaměňovat se **neslučitelností** – neslučitelné jevy nemohou nastat současně: $P(A \cap B) = 0$.
- Dvojice jevů může být:
 - **Neslučitelná a závislá** – např. „padla 1“ a „padla 6“
 - **Nezávislá a slučitelná** – např. „padla sudá“ a „padla větší než 3“
- V praxi ověřujeme nezávislost pomocí výpočtu $P(A \cap B)$ a porovnáním s $P(A) \cdot P(B)$

Klasická (Laplaceova) definice pravděpodobnosti

- Náhodný pokus má n různých stejně pravděpodobných výsledků.
- Pravděpodobnost jevu $A \subseteq \Omega$ je:

$$P(A) = \frac{|A|}{|\Omega|}$$

- Tento model je vhodný pouze pro konečné diskrétní prostory s rovnoměrnými rozděleními.
- Nevhodný pro spojitě rozdělení nebo nekonečné množiny – zde se uplatňuje Kolmogorovův přístup.

Podmíněná pravděpodobnost

- **Podmíněná pravděpodobnost** je pravděpodobnost jevu A za předpokladu, že nastal jev B . Značí se $P(A|B)$ a definuje se jako:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad \text{pouze pokud } P(B) > 0$$

- Znamená to, že podmíněná pravděpodobnost výskytu A , pokud víme, že nastal B , je rovna pravděpodobnosti průniku obou jevů dělené pravděpodobností B .
- Tato definice odpovídá intuitivnímu chápání „pravděpodobnosti za předpokladu“. Upřesňuje, jak se mění pohled na pravděpodobnost, když víme, že se určitý jev již stal.
- Z podmíněné pravděpodobnosti vyplývá také užitečná identita (úplný zákon pravděpodobnosti):

$$P(A) = P(A|B) \cdot P(B) + P(A|B^c) \cdot P(B^c)$$

- To znamená, že pravděpodobnost jevu A lze rozdělit podle toho, zda nastal B nebo jeho doplněk.

- **Řetězové pravidlo** (chain rule): Pravděpodobnost výskytu posloupnosti jevů lze zapsat jako součin podmíněných pravděpodobností:

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdot \dots \cdot P(A_n|A_1 \cap \dots \cap A_{n-1})$$

- Například pro posloupnost hodů kostkou můžeme psát:

$$P(1, 4, 6, 2) = P(1) \cdot P(4|1) \cdot P(6|1 \cap 4) \cdot P(2|1 \cap 4 \cap 6)$$

- **Nezávislost jevů a podmíněná pravděpodobnost:**

- Jevy A a B jsou **nezávislé**, právě když:

$$P(A|B) = P(A) \quad \text{a} \quad P(B|A) = P(B)$$

- Z toho plyne i definice pro průnik: $P(A \cap B) = P(A) \cdot P(B)$

- **Podmíněná nezávislost:**

- Jevy A a B jsou **podmíněně nezávislé** vzhledem k C , pokud:

$$P(A \cap B|C) = P(A|C) \cdot P(B|C)$$

- To znamená, že pokud víme, že nastal jev C , pak A a B jsou vůči sobě nezávislé.

Bayesova věta

- **Bayesova věta** je základní vztah v teorii pravděpodobnosti, který umožňuje *obrátit* podmíněné pravděpodobnosti. Z vyjádření pravděpodobnosti $P(B|A)$ získáme $P(A|B)$:

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

- pouze pokud $P(B) > 0$
- Tento vzorec umožňuje odhadnout pravděpodobnost jevu A za předpokladu, že nastal B , na základě znalosti pravděpodobnosti B za podmínky A (tzv. likelihood) a apriorní pravděpodobnosti A .

- **Interpretace:**

- $P(A)$ – apriorní pravděpodobnost jevu A (např. pravděpodobnost nemoci před testováním)
- $P(B|A)$ – pravděpodobnost pozorování B za předpokladu A (např. pozitivní test pokud je nemoc)
- $P(B)$ – celková pravděpodobnost jevu B (např. celková pravděpodobnost pozitivního testu)
- $P(A|B)$ – aposteriorní pravděpodobnost (pravděpodobnost, že má pacient nemoc, když test vyšel pozitivně)

- **Rozšíření na více jevů – věta o úplné pravděpodobnosti a Bayesův vzorec:**

- Pokud máme úplný systém disjunktních jevů $A_1, A_2, \dots, A_n$ (např. různé možné příčiny nějakého jevu), a známe pravděpodobnosti $P(A_i)$ a podmíněné pravděpodobnosti $P(B|A_i)$, pak:

$$P(B) = \sum_{j=1}^n P(A_j) \cdot P(B|A_j)$$

- A Bayesova věta pro konkrétní A_i :

$$P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{\sum_{j=1}^n P(A_j) \cdot P(B|A_j)}$$

- **Praktický příklad – falešně pozitivní testy (FP), pravdivě pozitivní (TP), atd.:**

- Např. pravděpodobnost, že pacient má nemoc (A), když test (B) je pozitivní:
 - $P(A)$ – pravděpodobnost, že má nemoc
 - $P(B|A)$ – test odhalí nemoc (true positive rate)
 - $P(B|\neg A)$ – test je falešně pozitivní (false positive rate)
 - $P(\neg A)$ – nemá nemoc

- Pak:

$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(A) \cdot P(B|A) + P(\neg A) \cdot P(B|\neg A)}$$

- **Význam v praxi:**

- Základní nástroj v medicíně (diagnostika), strojovém učení (naivní Bayesův klasifikátor), rozhodování s neúplnými informacemi.

Náhodná veličina

Náhodná veličina je **měřitelná funkce** $X : \Omega \rightarrow \mathbb{R}$, která každému elementárnímu jevu $\omega \in \Omega$ přiřadí reálné číslo. Je definována na pravděpodobnostním prostoru $(\Omega, \mathcal{A}, P)$. Měřitelnost znamená, že pro každý interval $I \subseteq \mathbb{R}$ je množina $\{\omega \in \Omega : X(\omega) \in I\} \in \mathcal{A}$, tj. lze jí přiřadit pravděpodobnost.

- **Distribuční funkce** náhodné veličiny X je funkce:

$$F_X(t) = P(X \leq t)$$

- Je to neklesající, zprava spojitá funkce, začínající v 0 a konvergující k 1. Popisuje pravděpodobnost, že náhodná veličina X nabude hodnoty menší nebo rovné t .
- **Hustota pravděpodobnosti** (pokud existuje) je derivací distribuční funkce:

$$f_X(t) = \frac{dF_X(t)}{dt}, \quad f_X(t) \geq 0$$

- Pravděpodobnost intervalu:

$$P(a < X \leq b) = F_X(b) - F_X(a) = \int_a^b f_X(t) dt$$

- Základní vlastnosti hustoty:

- $f_X(x) \geq 0$
- $\int_{-\infty}^{\infty} f_X(x) dx = 1$

- **Pravděpodobnostní funkce** (pro diskrétní náhodné veličiny - pravděpodobnost, že náhodná veličina X nabude konkrétní hodnoty t):

$$p_X(t) = P(X = t)$$

- **Pravděpodobnostní míra** P_X určuje pravděpodobnost jevů náhodné veličiny X a splňuje:

- $P_X(\mathbb{R}) = 1$
- $P_X(\emptyset) = 0$
- Pokud jsou množiny B_i disjunktní, pak $P_X(\bigcup_i B_i) = \sum_i P_X(B_i)$


Diskrétní náhodná veličina

Nabývá konečný nebo spočetný počet hodnot. Distribuční funkce je **schodová**, pravděpodobnost konkrétní hodnoty je dána pravděpodobnostní funkcí:

$$p(t) = P(X = t) = \sum_i p_i \delta(t - t_i)$$

- kde δ je Diracova funkce.

- Platí $\sum_i p_i = 1$
- Pro libovolný interval: $P(a < X \leq b) = \sum_{i: a < t_i \leq b} p_i$



Spojitá náhodná veličina

Nabývá nekonečně mnoho hodnot. Distribuční funkce je **spojitá**, ale pravděpodobnost, že veličina nabude konkrétní hodnoty, je vždy nulová:


$$P(X = t) = 0 \quad \text{pro všechna } t \in \mathbb{R}$$

- Hustota pravděpodobnosti je definována jako (ale pravděpodobnost, že náhodná veličina nabude konkrétní hodnoty, je vždy 0.):

$$f_X(t) = \frac{dF_X(t)}{dt}$$

- A platí:

$$F_X(t) = \int_{-\infty}^t f_X(u) du$$



Smíšená náhodná veličina

Nabývá jak diskrétních, tak spojitých hodnot. Distribuční funkce obsahuje **diskrétní schody** i **spojité části**.
Hustota:

$$f(t) = \sum_i p_i \delta(t - t_i) + f_c(t)$$

kde p_i jsou pravděpodobnosti diskrétních hodnot t_i a $f_c(t)$ je hustota spojitě části.

Střední hodnota, rozptyl a směrodatná odchylka

Střední hodnota (očekávaná hodnota) náhodné veličiny X je definována jako „vážený průměr“ hodnot, které může X nabývat, kde váhou je pravděpodobnost výskytu těchto hodnot.

- Pro **spojitou náhodnou veličinu** s hustotou pravděpodobnosti $f(t)$ platí:

$$E(X) = \int_{-\infty}^{\infty} t f(t) dt$$

- Pro **diskrétní náhodnou veličinu**, která nabývá hodnot t_i s pravděpodobnostmi p_i , je očekávaná hodnota dána součtem:

$$E(X) = \sum_i t_i p_i$$

Střední hodnota tedy představuje „průměrnou“ hodnotu, kterou bychom očekávali při velkém počtu opakování náhodného pokusu.

Poznámka: Lze ji také zapsat pomocí distribuční funkce:

$$E(X) = \int_{-\infty}^{\infty} x dF(x)$$

pokud integrál existuje. V diskrétním případě lze výpočet provést přes konvergentní řadu:

$$E(X) = \sum_{i=1}^{\infty} x_i \cdot p_i$$

Rozptyl (variance) náhodné veličiny X popisuje, jak moc se hodnoty náhodné veličiny „rozptylují“ kolem její střední hodnoty. Je to očekávaná hodnota druhé mocniny odchylky od střední hodnoty:

$$Var(X) = E((X - E(X))^2)$$

Tuto definici lze přepsat pomocí tzv. Steinerovy věty do ekvivalentního tvaru:

$$Var(X) = E(X^2) - (E(X))^2$$

kde $E(X^2)$ je očekávaná hodnota druhé mocniny veličiny X .

Rozptyl měří míru „rozptýlení“ hodnot kolem průměru. Čím vyšší rozptyl, tím větší je variabilita dat.

Směrodatná odchylka (standard deviation) je druhá odmocnina rozptylu:

$$\sigma(X) = \sqrt{Var(X)}$$

Jedná se o často používanou míru variability, protože má stejné jednotky jako původní veličina (na rozdíl od rozptylu, který má jednotky druhé mocniny).

Moment náhodné veličiny X je obecné rozšíření střední hodnoty a definuje se jako očekávaná hodnota k -té mocniny náhodné veličiny:

- Pro spojitou náhodnou veličinu:

$$M_k(X) = E(X^k) = \int_{-\infty}^{\infty} t^k f(t) dt$$

- Pro diskrétní náhodnou veličinu:

$$M_k(X) = \sum_i t_i^k p_i$$

Momenty slouží k popisu tvaru rozdělení (např. šikmost, špičatost), přičemž:

- $M_1(X)$ je střední hodnota,
- $M_2(X) - (M_1(X))^2$ je rozptyl,
- vyšší momenty popisují například „šikmost“ nebo „špičatost“ rozdělení.

Existují i tzv. **centrální momenty**, které mají tvar:

$$\mu_k = E((X - E(X))^k)$$

Například druhý centrální moment je právě rozptyl.

Základní typy rozdělení

Diskrétní rozdělení

Binomické rozdělení – popisuje počet úspěchů v n nezávislých Bernoulliho pokusech, kde každý pokus má pravděpodobnost úspěchu p . Distribuční funkce je dána jako:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n$$

Střední hodnota $EX = np$, rozptyl $var X = np(1-p)$.

Poissonovo rozdělení – popisuje počet událostí v pevném intervalu při konstantní intenzitě λ . Distribuční funkce je:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

Střední hodnota i rozptyl $EX = var X = \lambda$.

Geometrické rozdělení – popisuje **počet neúspěchů před prvním úspěchem** v sérii nezávislých Bernoulliho pokusů s pravděpodobností úspěchu p . Distribuční funkce je:

$$P(X = k) = p(1-p)^k, \quad k = 0, 1, 2, \dots$$

Střední hodnota $EX = \frac{1-p}{p}$, rozptyl $var X = \frac{1-p}{p^2}$. *(Pozn.: V některých definicích se udává počet pokusů do prvního úspěchu ($k = 1, 2, \dots$), materiály však explicitně uvádějí $k = 0$).*

Alternativní (Bernoulliho) rozdělení – popisuje **jediný pokus** s pravděpodobností úspěchu p . Nabývá hodnot:

- $X = 1$ (úspěch) s $P(X = 1) = p$
- $X = 0$ (neúspěch) s $P(X = 0) = 1 - p$
- Střední hodnota $EX = p$, rozptyl $var X = p(1-p)$.
- (Pozn.: Popis „počet pokusů do prvního úspěchu s různými p_i “ neodpovídá $Alt(p)$ v materiálech).*

Rovnoměrné rozdělení – popisuje náhodnou veličinu nabývající hodnot $a, a+1, \dots, b$ s rovnoměrnou pravděpodobností:

$$P(X = k) = \frac{1}{b-a+1}, \quad k = a, a+1, \dots, b$$

Hypergeometrické rozdělení

- popisuje počet úspěchů při n náhodných výběrech bez vracení z populace N s K úspěšnými položkami:

$$P(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}, \quad k = \max(0, n - (N - K)), \dots, \min(K, n)$$

Střední hodnota $E(X) = n \frac{K}{N}$.

Spojitá rozdělení

Rovnoměrné rozdělení – popisuje náhodnou veličinu na intervalu $[a, b]$ s konstantní hustotou:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{jinak} \end{cases}$$

Distribuční funkce:

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

$$E[X] = \frac{b-a}{2} \quad \text{Var}(X) = \frac{(b-a)^2}{12}.$$

Normální rozdělení – symetrické rozdělení se střední hodnotou μ a rozptylem σ^2 . Hustota:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Distribuční funkce $\Phi(x)$ nemá uzavřený tvar. Speciální případ: **N(0,1)** s hustotou $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$.

Exponenciální rozdělení – popisuje **dobu mezi událostmi v Poissonově procesu** s intenzitou λ : Hustota:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Distribuční funkce:

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

2. Náhodné vektory a jejich popis

Náhodné vektory a jejich popis – nezávislost náhodných veličin, kovariance a korelace.

Náhodný vektor je n -rozměrný vektor $(X_1, X_2, \dots, X_n)$, kde každá složka X_i je náhodná veličina – měřitelná funkce definovaná na stejném pravděpodobnostním prostoru $(\Omega, \mathcal{A}, P)$, která každému elementárnímu jevu přiřadí reálnou hodnotu.

- Náhodný vektor můžeme chápat buď jako množinu náhodných veličin zkoumaných současně, nebo jako jednu náhodnou veličinu zkoumanou na několika objektech.
- Jedná se o zobrazení z Ω do $\mathbb{R}^n$.

Společná distribuční funkce (distribuční funkce náhodného vektoru) je definována jako:

$$F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

- Tato funkce je:
 - neklesající v každé proměnné,
 - zprava spojitá,
 - její limity jsou 0 v $-\infty$ a 1 v $+\infty$.

Pro **spojitý náhodný vektor** existuje společná hustota pravděpodobnosti $f(x_1, \dots, x_n)$ taková, že:

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_1 \cdots dt_n$$

Nezávislost náhodných veličin

Náhodné veličiny $X_1, X_2, \dots, X_n$ jsou **nezávislé**, pokud pro všechny $x_1, x_2, \dots, x_n$ platí:

$$F(x_1, x_2, \dots, x_n) = F_1(x_1) \cdot F_2(x_2) \cdots F_n(x_n)$$

kde $F_i(x_i)$ je marginální distribuční funkce každé jednotlivé složky X_i .

- Pro **spojité** náhodné veličiny je nezávislost ekvivalentní s podmínkou:

$$f(x_1, \dots, x_n) = f_1(x_1) \cdot \dots \cdot f_n(x_n)$$

- Pokud náhodné veličiny nejsou nezávislé, může se jedna veličina ovlivňovat s jinou.
- Pro úplnou nezávislost všech n veličin je třeba, aby byly nezávislé i všechny jejich kombinace.

Součet náhodných veličin – pokud jsou X a Y nezávislé, pak distribuční funkce jejich součtu $Z = X + Y$ vznikne tzv. **konvolucí**:

- Pro diskrétní veličiny:

$$P(Z = z) = \sum_i P(X = x_i) \cdot P(Y = z - x_i)$$

- Pro spojité veličiny:

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(t) \cdot f_Y(z - t) dt$$

Příklady konvoluce rozdělení:

- $Alt(p) + Alt(p) = Bin(2, p)$
- $Bin(n_1, p) + Bin(n_2, p) = Bin(n_1 + n_2, p)$
- $Po(\lambda_1) + Po(\lambda_2) = Po(\lambda_1 + \lambda_2)$
- $N(\mu_1, \sigma_1^2) + N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

Kovariance a korelace

Kovariance je míra lineární závislosti dvou náhodných veličin X a Y :

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

- Pokud $\text{Cov}(X, Y) > 0$, mezi X a Y existuje pozitivní lineární závislost.
- Pokud $\text{Cov}(X, Y) < 0$, závislost je negativní.
- Pokud $\text{Cov}(X, Y) = 0$, X a Y jsou lineárně nezávislé (ale nemusí být obecně nezávislé).

Vlastnosti kovariance:

- $\text{Cov}(X, X) = \text{Var}(X)$
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- $\text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$

Korelace (Pearsonův korelační koeficient) je normovaná kovariance, která měří sílu a směr lineární závislosti mezi veličinami:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

- $\rho(X, Y) \in [-1, 1]$
- $\rho = 1$ znamená úplnou pozitivní lineární závislost
- $\rho = -1$ znamená úplnou negativní lineární závislost
- $\rho = 0$ značí, že mezi veličinami není lineární závislost (ale může být nelineární)

Kovarianční matice a korelační matice:

- Pro náhodný vektor $X = (X_1, \dots, X_n)^T$ se definuje střední hodnota vektoru:

$$E[X] = (E[X_1], E[X_2], \dots, E[X_n])^T$$

- Kovariance mezi složkami tvoří **kovarianční matici**:

$$\Sigma = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

- Korelace tvoří **korelační matici**, kde jsou jednotlivé prvky korelačními koeficienty mezi dvojicemi složek.

3. Čebyševova nerovnost

Čebyševova nerovnost – centrální limitní věta.

Čebyševova nerovnost je matematická nerovnost, která říká, jak velká část pravděpodobnostní hmoty náhodné veličiny leží blízko její střední hodnoty. Je velmi obecná, protože nevyžaduje znalost konkrétního rozdělení – stačí znát pouze střední hodnotu a rozptyl.

Teoretické vzorce: Pro náhodnou veličinu X s konečným rozptylem platí:

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}, \quad \text{pro každé } \varepsilon > 0$$

kde

- $E(X)$ je střední hodnota náhodné veličiny X
- $\text{Var}(X)$ je rozptyl náhodné veličiny X

Myšlenka:

Čebyševova nerovnost udává **horní odhad pravděpodobnosti**, že se hodnota náhodné veličiny odchýlí od své střední hodnoty o více než ε . I když nerozumíme přesnému rozdělení, můžeme tímto způsobem říci, že většina hodnot leží „blízko průměru“.

- Využití: odhad pravděpodobnosti odlehlých hodnot (outliers) bez nutnosti znát konkrétní rozdělení.


Praktická ukázka:

Mějme náhodnou veličinu X se střední hodnotou $E(X) = 50$ a rozptylem $\text{Var}(X) = 25$. Chceme zjistit pravděpodobnost, že se X odchýlí od 50 o více než 10:

$$P(|X - 50| \geq 10) \leq \frac{25}{10^2} = 0.25$$

Interpretace: Nejvýše 25 % hodnot může být mimo interval $[40, 60]$. To znamená, že alespoň 75 % hodnot leží v tomto intervalu.

Grafické znázornění:



Vysvětlení: Červené oblasti znázorňují pravděpodobnost odchylky od μ o více než ε . Jejich plocha je shora omezena $\frac{\sigma^2}{\varepsilon^2}$.

Centrální limitní věta (CLV)

Centrální limitní věta (CLV) je základní výsledek pravděpodobnosti a statistiky, který říká, že součet (nebo průměr) mnoha nezávislých náhodných veličin má přibližně normální rozdělení – bez ohledu na původní rozdělení jednotlivých veličin.

Teoretický vzorec:

Nechť $X_1, X_2, \dots, X_n$ jsou nezávislé, stejně rozdělené náhodné veličiny se střední hodnotou μ a konečným rozptylem σ^2 . Potom platí:

$$Z_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sigma\sqrt{n}} \Rightarrow \mathcal{N}(0, 1) \quad \text{pro } n \rightarrow \infty$$

Jinými slovy, rozdělení Z_n konverguje k normovanému normálnímu rozdělení (s průměrem 0 a směrodatnou odchylkou 1).

Pak pro $n \rightarrow \infty$ platí:

$$\lim_{n \rightarrow \infty} P(Z_n \leq x) = \Phi(x),$$

kde $\Phi(x)$ je distribuční funkce normovaného normálního rozdělení $\mathcal{N}(0, 1)$.

Myšlenka:

CLV ukazuje, že **výběrový průměr** (nebo součet) mnoha nezávislých veličin má přibližně **normální rozdělení**, i když původní data nejsou normální. To umožňuje používat normální rozdělení pro aproximace (např. v testování hypotéz).

Praktická ukázka:

Představme si, že házíme klasickou kostkou 100krát. Střední hodnota jednoho hodu je $\mu = 3.5$ a rozptyl je $\sigma^2 = \frac{35}{12} \approx 2.92$.

Chceme zjistit pravděpodobnost, že výběrový průměr všech hodů bude větší než 4.

1. Standardizace:

$$Z = \frac{4 - 3.5}{\sqrt{2.92/100}} \approx \frac{0.5}{0.171} \approx 2.93$$


2. Použití tabulky normálního rozdělení:

$$P(\bar{X} > 4) = 1 - \Phi(2.93) \approx 1 - 0.9983 = 0.0017$$

Interpretace: Pravděpodobnost, že výběrový průměr přesáhne 4, je velmi malá (přibližně 0.17 %), což dává smysl – je totiž málo pravděpodobné, že by padaly výhradně vysoké hodnoty.

Poznámka: Rychlost konvergence k normálnímu rozdělení je dána tzv. **Berry-Essenovou nerovností** – čím větší n , tím přesnější aproximace.

Grafické znázornění:



Vysvětlení: Modré sloupce znázorňují např. rozdělení hodu kostkou. Červená křivka ukazuje konvergenci výběrového průměru k normálnímu rozdělení s rostoucím n .

4. Základní pojmy statistiky

Základní pojmy statistiky – náhodný výběr, empirické rozdělení.

Náhodný výběr

Náhodný výběr je posloupnost n nezávislých a stejně rozdělených náhodných veličin $X_1, X_2, \dots, X_n$ reprezentujících data z populace. Formálně:

$$\{X_i\}_{i=1}^n \quad \text{kde} \quad X_i \sim F \quad (\text{i.i.d.})$$

- n : rozsah výběru
- F : společná distribuční funkce populace
- i.i.d.: *independent and identically distributed* (nezávislé a stejně rozdělené)

Tento koncept znamená, že každá jednotlivá hodnota ve výběru má stejnou pravděpodobnostní distribuci jako ostatní a je na nich nezávislá.

Příklad: Měření výšky 50 náhodně vybraných studentů $\rightarrow X_i =$ výška i -tého studenta. Každý student je vybrán náhodně, a tedy všechny výšky jsou považovány za i.i.d. realizace z určité distribuční funkce výšek ve studované populaci.

Empirické rozdělení

Empirické rozdělení aproximuje skutečné rozdělení populace pomocí dat z náhodného výběru.

- **Empirická distribuční funkce** $F_n(x)$:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}$$


kde $\mathbf{1}_{\{X_i \leq x\}} = 1$, pokud $X_i \leq x$, jinak 0.

- **Vlastnosti:**

- Skoková funkce s body nespojitosti v hodnotách X_i .
- Pro $n \rightarrow \infty$ platí $F_n(x) \rightarrow F(x)$ podle zákona velkých čísel.

Tato funkce udává relativní četnost hodnot ve výběru, které jsou menší nebo rovny hodnotě x , a tedy slouží jako aproximace skutečné distribuční funkce.

Příklad: Pro výběr $\{1,5; 2,0; 3,5\}$ je $F_n(x)$ skoková funkce s třemi skoky o velikosti $\frac{1}{3}$, která stoupá vždy, když x překročí jednu z hodnot výběru.



5. Obecné vlastnosti odhadů parametrů

Při odhadování neznámých parametrů základního souboru na základě pozorovaných dat z náhodného výběru se snažíme, aby naše odhady měly určité žádoucí vlastnosti. Tyto vlastnosti nám pomáhají posoudit kvalitu odhadu a vybrat ten nejlepší možný. Odhad je pravidlo nebo funkce, která na základě dat z výběru přiřazuje hodnotu určitému neznámému parametru.

Značení

Nejprve si zavedeme značení, které se v teorii odhadu běžně používá:

- ϑ : Jakákoli hodnota parametru (reálné číslo).
- ϑ^* : Skutečná (správná) hodnota parametru (reálné číslo).
- $\hat{\Theta}_n$: Odhad parametru založený na náhodném výběru rozsahu n (toto je náhodná veličina).
- $\hat{\vartheta}, \hat{\vartheta}_n$: Realizace odhadu, tj. konkrétní hodnota odhadu získaná z dat (reálné číslo).

Například: Pokud odhadujeme střední hodnotu výšky v populaci, pak ϑ je neznámá střední výška, $\hat{\Theta}_n$ je výběrový průměr (náhodná veličina závislá na výběru) a $\hat{\vartheta}$ je konkrétní hodnota výběrového průměru vypočtená z dat.

Žádoucí vlastnosti bodových odhadů

Bodový odhad je funkce náhodného výběru, jejíž předpis nezávisí na odhadovaném parametru. Snažíme se, aby bodové odhady měly následující vlastnosti:

1. Nestrannost (nevychýlenost)

- Odhad $\hat{\Theta}_n$ se nazývá nestranný, pokud jeho střední hodnota je rovna skutečné hodnotě parametru ϑ^* , tj. $E[\hat{\Theta}_n] = \vartheta^*$
 - což znamená, že: $E[\hat{\Theta}_n - \vartheta^*] = 0$
- Pokud tato podmínka není splněna, říkáme, že odhad je **vychýlený** (má systematickou chybu).
- Příklad: Výběrový průměr je nestranný odhad střední hodnoty normálního rozdělení.

2. Asymptotická nestrannost

- Odhad $\hat{\Theta}_n$ je asymptoticky nestranný, pokud se jeho střední hodnota blíží skutečné hodnotě parametru ϑ^* s rostoucím rozsahem výběru n , tj. $\lim_{n \rightarrow \infty} E[\hat{\Theta}_n] = \vartheta^*$
- To znamená, že odhad je sice pro malé n vychýlený, ale bias se s rostoucím n zmenšuje a nakonec zmizí.
- Např. výběrový rozptyl s dělením n místo $n - 1$ je asymptoticky nestranný.

3. Konzistence

- Odhad $\hat{\Theta}_n$ je konzistentní, pokud s rostoucím rozsahem výběru n konverguje v pravděpodobnosti k odhadovanému parametru ϑ^* , tj.: $\hat{\Theta}_n \xrightarrow{P} \vartheta^*$
- To znamená, že:
 - Je asymptoticky nestranný: $\lim_{n \rightarrow \infty} E[\hat{\Theta}_n] = \vartheta^*$
 - A má klesající rozptyl: $\lim_{n \rightarrow \infty} D[\hat{\Theta}_n] = 0$
- Konzistence znamená, že s větším počtem dat bude náš odhad přesnější.

4. Efektivita (účinnost)

- Efektivní odhad je takový, který má co nejmenší střední kvadratickou chybu: $E[(\hat{\Theta}_n - \vartheta^*)^2]$
- Tuto chybu můžeme rozložit na: $D[\hat{\Theta}_n] + (E[\hat{\Theta}_n] - \vartheta^*)^2$
- Pro **nestranné odhady** tedy platí, že efektivita závisí pouze na jejich rozptylu.
- **Nejlepší nestranný odhad** (MVUE – minimum variance unbiased estimator) má ze všech nestranných odhadů nejmenší rozptyl.
- Pozor: může se stát, že některé vychýlené odhady jsou efektivnější než MVUE – mají menší celkovou chybu.

5. Robustnost

- Robustní odhad je odolný vůči šumu nebo odlehlým hodnotám (například extrémním datům v souboru).
- Nemusí být neefektivnější při ideálních podmínkách, ale je stabilnější v praxi, kde jsou data často zašuměná nebo obsahují chyby.
- Přesná matematická definice robustnosti často neexistuje, ale prakticky se jedná o velmi důležitou vlastnost.
- Příklad: Medián je robustnější než průměr, protože není ovlivněn extrémními hodnotami.

Odhady konkrétních parametrů

- **Odhady střední hodnoty (μ):**
 - Výběrový průměr $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
 - je nestranným a konzistentním odhadem střední hodnoty $E[X]$.
 - To znamená, že jeho střední hodnota je rovna skutečné střední hodnotě populace, a že s rostoucím počtem dat se přibližuje pravé hodnotě μ .
 - Příklad: Pokud měříme výšku 100 studentů, průměr těchto hodnot odhaduje průměrnou výšku celé populace studentů.
- **Odhady rozptylu (σ^2):**
 - Výběrový rozptyl $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$
 - je nestranným a konzistentním odhadem rozptylu $D[X]$.
 - Dělení $n - 1$ místo n zajišťuje nestrannost odhadu (tzv. Besselova korekce).
 - Tento odhad popisuje, jak moc se jednotlivé hodnoty výběru rozptylují kolem výběrového průměru.
- **Odhady směrodatné odchylky (σ):**
 - Výběrová směrodatná odchylka se definuje jako odmocnina výběrového rozptylu: $S_n = \sqrt{S_n^2}$
 - Je přirozeným odhadem směrodatné odchylky a udává, jak moc se hodnoty typicky liší od průměru v původních jednotkách.
- **Odhady momentů:**
 - Pro odhad k -tého obecného momentu $E[X^k]$ použijeme výběrový moment: $m_{X^k} = \frac{1}{n} \sum_{j=1}^n x_j^k$
 - Tento moment slouží např. k odhadu tvaru rozdělení (šikmost, špičatost) podle toho, zda se jedná o 3., 4. atd. moment.
 - Příklad: Výběrový druhý moment je základem pro výpočet rozptylu.

Metody odhadování parametrů

Existuje několik metod, jak na základě dat odhadnout neznámé parametry rozdělení. Nejčastěji používané jsou tyto dvě:

1. Metoda momentů (MM)

- **Princip:** Vycházíme z předpokladu, že teoretické momenty náhodné veličiny (např. střední hodnota, rozptyl atd.) závisí na parametrech rozdělení. Tyto teoretické momenty nahradíme jejich výběrovými odhady spočítanými z dat a vyřešíme rovnice, které takto vzniknou.
- **Cíl:** Najít takové hodnoty parametrů, aby teoretické vlastnosti rozdělení (momenty) „odpovídaly“ těm vypočteným z dat
- **Postup (příklad pro dva parametry θ_1 a θ_2):**
 - Sečteme data a spočítáme výběrové momenty:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

- Sestavíme rovnice z teoretických momentů $E[X]$, $E[X^2]$ (ty závisí na θ_1, θ_2) a položíme je rovné výběrovým momentům.
- Řešíme soustavu rovnic a získáme odhady parametrů.
- **Výhody:**
 - Poměrně jednoduchá metoda, často poskytuje uzavřené (analytické) řešení.
 - Zohledňuje všechna data.
 - Nemí potřeba znát přesnou formu pravděpodobnostní funkce.
- **Nevýhody:**
 - Řešení nemusí existovat nebo může být nejednoznačné.
 - Odhady nemusí být nejpřesnější (např. ve smyslu rozptylu).
- **Poznámka:**
 - Používá se např. tehdy, když je výpočetně náročné použít metodu maximální věrohodnosti.

2. Metoda maximální věrohodnosti (MLE – Maximum Likelihood Estimation)

- **Princip:** Hledáme takovou hodnotu parametru θ , která **maximalizuje pravděpodobnost pozorovaných dat**. Jinými slovy: jaké nastavení parametrů by „nejlépe vysvětlovalo“ data, která jsme viděli?
- **Postup:**
 - Sestrojíme věrohodnostní funkci $L(\theta)$:
 - Spojitý případ:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

- Diskrétní případ:

$$L(\theta) = \prod_{i=1}^n P(X_i = x_i; \theta)$$

- Z logaritmu věrohodnostní funkce vytvoříme tzv. **log-věrohodnost**:

$$\ell(\theta) = \ln L(\theta)$$

- Přejít na logaritmus je praktický – převádí součiny na součty, což zjednoduší derivování.
- Najdeme extrém log-věrohodnosti:
 - Vypočteme derivaci podle θ , položíme ji rovnu nule a řešíme:

$$\frac{\partial \ell(\theta)}{\partial \theta} = 0$$

- Výsledné řešení $\hat{\theta}$ je maximálně věrohodný odhad parametru.
- **Výhody:**
 - Při splnění určitých podmínek poskytuje MLE odhady s dobrými vlastnostmi – jsou asymptoticky nestranné, efektivní a konzistentní.
 - Obvykle poskytuje přesnější výsledky než metoda momentů.
- **Nevýhody:**
 - V některých případech může být složité nebo nemožné analyticky řešit rovnici pro maximum.

- Výsledky mohou být citlivé na odlehle hodnoty.
- **Poznámka:**
 - V jednoduchých situacích (např. normální rozdělení) obě metody vedou ke stejným odhadům.
 - V praxi se metoda volí podle dostupnosti informací o rozdělení a výpočetní náročnosti.

Intervalové odhady (Intervaly spolehlivosti)

Na rozdíl od bodového odhadu, který poskytuje pouze jednu hodnotu pro neznámý parametr, intervalový odhad poskytuje **interval**, ve kterém se s určitou pravděpodobností nachází skutečná hodnota tohoto parametru. Tento přístup lépe vystihuje nejistotu spojenou s odhadem.

- **Definice:** $(1 - \alpha) \times 100\%$ **interval spolehlivosti** pro parametr ϑ je interval (L, U) takový, že:

$$P(L < \vartheta^* < U) \geq 1 - \alpha$$

- kde:
 - L je dolní mez intervalu,
 - U je horní mez intervalu,
 - ϑ^* je skutečná (neznámá) hodnota parametru.
- **Koeficient spolehlivosti** $(1 - \alpha)$ vyjadřuje pravděpodobnost, že interval pokrývá skutečnou hodnotu parametru. Například:
 - Pro 95% spolehlivost platí $\alpha = 0.05$.
 - Pro 99% spolehlivost platí $\alpha = 0.01$.
- **Hladina významnosti** α představuje pravděpodobnost, že skutečný parametr **leží mimo** interval (tj. že interval není „úspěšný“). Často se dělí na dvě části – pro dolní a horní mez (např. $\alpha/2$ a $\alpha/2$).
- Existují různé typy intervalových odhadů:
 - **Oboustranný interval:**

$$I = (L, U)$$

- kde interval symetricky pokrývá oblast kolem bodového odhadu.

- **Dolní jednostranný interval:**

$$I = (L, \infty)$$

- **Horní jednostranný interval:**

$$I = (-\infty, U)$$

- **Symetrický oboustranný interval** je takový, kde pravděpodobnost, že parametr leží pod dolní mezí, i nad horní mezí, je stejná, tedy:

$$P(\vartheta^* < L) = P(\vartheta^* > U) = \frac{\alpha}{2}$$

- Abychom mohli interval spolehlivosti zkonstruovat, musíme znát **pravděpodobnostní rozdělení bodového odhadu** $\hat{\Theta}_n$, případně rozdělení vhodné statistiky, která z něj vychází (např. pomocí normálního nebo t-rozdělení).

Intervalové odhady konkrétních parametrů

Odhad střední hodnoty se známým rozptylem pomocí kvantilů normálního rozdělení (u): Pokud známe rozptyl populace σ^2 , použijeme normální rozdělení. Interval spolehlivosti pro střední hodnotu μ se pak určuje pomocí kvantilu u z normálního rozdělení. Tento přístup je vhodný, když víme, že data pocházejí z normálního rozdělení **a zároveň známe rozptyl**.

Odhad střední hodnoty a rozptylu pomocí kvantilů t a χ^2 : Pokud je rozptyl neznámý, pro odhad střední hodnoty použijeme **Studentovo t-rozdělení**, které zohledňuje nejistotu ve výběrovém rozptylu. Pro intervalový odhad

rozptylu použijeme **chí-kvadrát rozdělení** – dolní a horní mez intervalu spočteme pomocí kvantilů z χ^2 .

Odhad střední hodnoty pomocí centrální limitní věty (CLV): Pokud výběr není z normálního rozdělení, ale máme dostatečně velký počet pozorování, použijeme CLV. Ta zaručuje, že výběrový průměr má přibližně normální rozdělení, takže můžeme použít normální kvantily u i bez normality původního rozdělení.

Asymptotický intervalový odhad: Používá se v obecných případech, kdy neznáme přesné rozdělení výběru, ale máme velký rozsah n . Intervaly jsou pak založené na odhadech ze vzorku (např. výběrový rozptyl místo známého rozptylu) a přibližují skutečné pokrytí při velkém n .

Poznámka: Lze tímto způsobem odhadovat i rozptyly, i když závisí na střední hodnotě. Typicky například u **Poissonova rozdělení**, kde platí $\mu = \sigma^2$, nebo u **alternativního rozdělení** (Bernoulliho), kde je rozptyl určen parametrem p a zároveň souvisí se střední hodnotou. V těchto případech se často využívají speciální odhady přizpůsobené danému typu rozdělení.

6. Princip statistického testování hypotéz

Princip statistického testování hypotéz – testy střední hodnoty a rozptylu, porovnání dvou rozdělení, χ^2 -test dobré shody, test nezávislosti v kontingenční tabulce.

Princip statistického testování hypotéz je metoda, jak ověřit, zda data poskytují dostatek důkazů pro zamítnutí nějakého předpokladu (tzv. hypotézy) o rozdělení nebo parametrech náhodných veličin. Tento postup je základem pro rozhodování v mnoha oblastech statistiky, experimentů a datové analýzy.

1. Formulace hypotéz:

- **Nulová hypotéza (H_0):** výchozí tvrzení, které předpokládáme, že platí – např. „střední hodnota je rovna 0“, „data mají normální rozdělení“, „dva výběry pochází ze stejné populace“ atd.
- **Alternativní hypotéza (H_1):** tvrzení, které se snažíme potvrdit – např. „střední hodnota se liší od 0“, „data nejsou normálně rozložena“, „dva výběry se liší“.
- Příklad:
 - $H_0: \mu = 50$
 - $H_1: \mu \neq 50$

2. Volba hladiny významnosti (α):

- Jedná se o pravděpodobnost chyby I. druhu – tj. že **zamítneme H_0 , i když je ve skutečnosti pravdivá**.
- Typicky se volí $\alpha = 0.05$ nebo $\alpha = 0.01$.
- Například při $\alpha = 0.05$ připouštíme maximálně 5% pravděpodobnost, že učiníme chybný závěr ve prospěch H_1 .

3. Výběr testové statistiky:

- Zvolíme vhodnou testovou statistiku v závislosti na typu dat a testované hypotéze.
 - Např. pro testování střední hodnoty normálně rozdělené veličiny použijeme t-test.
 - Pro rozptyl může být použit F-test.
 - Pro testy shody rozdělení použijeme např. χ^2 -test.
- Testová statistika je funkce vzorku, jejíž rozdělení známe, pokud H_0 platí.

4. Výpočet kritické hodnoty nebo p-hodnoty:

- **Kritická hodnota:** hodnota testové statistiky, kterou porovnáme s vypočtenou hodnotou. Jestliže překročí tuto mez, zamítáme H_0 .
- **p-hodnota:** pravděpodobnost, že bychom při platnosti H_0 získali stejně nebo více extrémní hodnotu testové statistiky. Pokud:

$$p\text{-hodnota} < \alpha,$$

- pak zamítáme H_0 .
- **Poznámka:** p-hodnota je velmi praktický způsob testování, protože přímo říká, jak „nepravděpodobná“ jsou data za předpokladu, že H_0 platí.

5. Rozhodnutí:

- Pokud $p\text{-hodnota} < \alpha$ **nebo** testová statistika je větší než kritická hodnota, **zamítáme H_0** .

- Jinak H_0 **nezamítáme** – což ale neznamená, že ji potvrzujeme; pouze nemáme dostatek důkazů k jejímu zamítnutí.

Shrnutí principu: Testování hypotéz je proces, jak rozhodnout, zda jsou odchylky pozorované ve vzorku od očekávaných hodnot důkazem proti výchozímu tvrzení. Pomáhá vyhnout se náhodným závěrům na základě šumu v datech, a umožňuje učinit rozhodnutí s kvantifikovanou mírou nejistoty.

Testy střední hodnoty a rozptylu

Testy střední hodnoty:

- **Jednovýběrový t-test:** Testuje hypotézu, zda střední hodnota jedné populace je rovna určité hodnotě. Používá se, pokud známe výběrový průměr a výběrový rozptyl a buď:
 - data pocházejí z normálního rozdělení, nebo
 - velikost výběru je dostatečně velká (např. $n > 30$, podle CLV).
 - **Příklad:** Zajímá nás, zda průměrná výška studentů přesahuje 175 cm.
- **Dvouvýběrový t-test:** Testuje, zda se liší střední hodnoty dvou nezávislých výběrů. Používá se při porovnání dvou skupin.
 - **Příklad:** Průměrná výška studentů v ČR vs. SR.
- **Párový t-test:** Testuje rozdíl středních hodnot dvou závislých výběrů, tj. každá hodnota v první skupině má přiřazenou dvojici v druhé skupině.
 - **Příklad:** Výška člověka před a po půlročním tréninku.

Testy rozptylu:

- **F-test:** Slouží ke srovnání dvou rozptylů. Je citlivý na odchylky od normality.
 - **Příklad:** Testujeme, zda se rozptyl známek ve dvou třídách liší.
- **χ^2 -test rozptylu:** Používá se k ověření, zda rozptyl náhodné veličiny je roven určité teoretické hodnotě.
 - Výpočet statistiky: $\chi^2 = \frac{(n-1) \cdot S^2}{\sigma_0^2}$
 - kde S^2 je výběrový rozptyl, σ_0^2 je hypotetická hodnota rozptylu a n velikost výběru.

Porovnání dvou rozdělení

Porovnání dvou rozdělení:

- **Kolmogorov-Smirnovův test:** Testuje, zda dvě empirické distribuční funkce se výrazně liší. Používá se u spojitých veličin. Citlivý k rozdílům ve tvaru rozdělení.
- **Mann-Whitneyho test:** Neparametrický test rozdílu středních hodnot mezi dvěma nezávislými skupinami. Nepotřebuje předpoklad normality – vhodný pro pořadová nebo ne-normální data.
- **Wilcoxonův test:** Neparametrický párový test – alternativní k párovému t-testu, když data nejsou normálně rozložena.

χ^2 -test dobré shody

Používá se pro ověření, zda četnosti pozorovaných dat odpovídají určitému teoretickému rozdělení (např. binomickému, Poissonovu, normálnímu). Vhodné např. pro kategorická data.

Výpočet testové statistiky:

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$$

kde:

- O_i jsou pozorované četnosti,
- E_i jsou teoreticky očekávané četnosti.

Předpoklady:

- Očekávané četnosti E_i by měly být větší nebo rovny 5, aby byl výsledek testu spolehlivý (jinak se používají úpravy nebo sloučení kategorií).

Test nezávislosti v kontingenční tabulce

Test nezávislosti:

- Používá se u dvou kategoriálních proměnných – např. pohlaví a preference typu produktu.
- Kontingenční tabulka zachycuje četnosti kombinací hodnot obou proměnných.

Testová statistika:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

kde:

- O_{ij} jsou pozorované četnosti v buňkách tabulky,
- E_{ij} jsou očekávané četnosti při nezávislosti proměnných: $E_{ij} = \frac{r_i \cdot c_j}{n}$
- kde r_i je součet řádku, c_j součet sloupce a n je celkový počet pozorování.

Interpretace:

- Malá hodnota χ^2 znamená, že rozdíly mezi O_{ij} a E_{ij} jsou malé $\rightarrow$ proměnné jsou pravděpodobně nezávislé.
- Velká hodnota χ^2 vede k zamítnutí hypotézy nezávislosti.

Předpoklad: Očekávané četnosti v buňkách by měly být alespoň 5.

7. Markovovy řetězce

Markovovy řetězce – modely náhodného vývoje systému v diskrétním čase, kde přechod do dalšího stavu závisí pouze na aktuálním stavu (tzv. *Markova vlastnost*).

Základní pojmy a popis

Markovův řetězec je posloupnost náhodných veličin $X_0, X_1, X_2, \dots$, kde pro každý n a všechny stavy $i_0, \dots, i_{n+1}$ platí:

$$P(X_{n+1} = i_{n+1} \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = i_{n+1} \mid X_n = i_n)$$

Tato rovnost říká, že vývoj závisí pouze na aktuálním stavu.

Pokud jsou pravděpodobnosti přechodu nezávislé na čase (tj. homogenní), pak označujeme:

$$p_{ij} = P(X_{n+1} = j \mid X_n = i)$$

a tyto pravděpodobnosti uspořádáme do **matice přechodu** $P = (p_{ij})$.

Součet pravděpodobností v každém řádku je roven 1:

$$\sum_j p_{ij} = 1 \quad \text{pro každé } i$$

n -tá mocnina matice P^n udává pravděpodobnosti přechodu za n kroků. Prvek $p_{ij}^{(n)}$ je pravděpodobnost, že se systém dostane ze stavu i do stavu j za právě n kroků.


Přechodový diagram a matice

Přechodový diagram je grafická reprezentace Markovova řetězce. Umožňuje vizuálně sledovat, jak se systém může pohybovat mezi jednotlivými stavy a s jakou pravděpodobností.

- **Uzly** představují možné **stavy systému** (např. A, B, C).
- **Orientované hrany** značí **možné přechody** mezi stavy.

- **Čísla na hranách** udávají **pravděpodobnosti přechodu** z jednoho stavu do druhého.

Diagram se tedy chová jako mapa dynamiky systému — zobrazuje nejen směr možného vývoje, ale i jeho pravděpodobnost.



Matice přechodu: Tento diagram můžeme přepsat do **matice přechodu** P , kde řádky odpovídají výchozím stavům a sloupce cílovým stavům. Hodnota na pozici p_{ij} je pravděpodobnost přechodu ze stavu i do stavu j .

	A	B	C
A	0.0	0.5	0.5
B	0.0	1.0	0.0
C	0.1	0.2	0.7

Jak číst tuto matici:

- První řádek: Pokud jsme ve stavu **A**, máme 0% šanci zůstat v A, 50% šanci jít do B a 50% do C.
- Druhý řádek: Ze stavu **B** se nikam jinam nedostaneme, zůstáváme v B (s pravděpodobností 1).
- Třetí řádek: Ze stavu **C** máme 10% šanci jít do A, 20% do B a 70% zůstat v C.

Rozložitelnost a komponenty

- **Rozložitelný řetězec** (reducibilní): Ne všechny stavy jsou vzájemně dosažitelné. Existují skupiny stavů, mezi kterými není přechod.
- **Nerazložitelný řetězec** (irreducibilní): Každý stav je dosažitelný z každého jiného – tvoří jednu komunikující třídu.
- **Uzavřená množina stavů:** Jakmile se do této množiny dostaneme, nemůžeme ji opustit.
- **Komponenta:** Největší možná uzavřená množina, která neobsahuje menší uzavřenou podmnožinu.

Asymptotické chování a stacionární rozdělení

Pro ireducibilní, aperiodický a pozitivně rekurentní řetězec existuje **stacionární rozdělení** $\pi = (\pi_1, \dots, \pi_n)$, které splňuje:

$$\pi = \pi P \quad \text{a} \quad \sum_{i=1}^n \pi_i = 1$$

- Toto rozdělení reprezentuje **dlouhodobé pravděpodobnosti** – tj. jaký podíl času systém stráví ve stavech v limitě $t \rightarrow \infty$.
- Lze ho nalézt jako **vlastní vektor** matice P k vlastnímu číslu 1.

Konvergence a rozklad matice

Pro markovský řetězec s trvalými a přechodnými stavy lze matici přechodu přepsat jako blokovou matici:

$$P = \begin{bmatrix} D & 0 \\ R & Q \end{bmatrix}$$

- D : přechody mezi trvalými stavy

- Q : přechody mezi přechodnými stavy
- R : přechody z přechodných do trvalých

Matice **fundamentální** $F = (I - Q)^{-1}$ a **absorpční pravděpodobnosti**:

$$M = F \cdot R = (I - Q)^{-1}R$$

vyjadřují pravděpodobnosti, že systém skončí v některém z trvalých stavů.

Asymptotické chování stavů

- **Přechodný stav**: $\lim_{n \rightarrow \infty} p_{ii}^{(n)} = 0$
- **Trvalý nulový stav**: $\lim_{n \rightarrow \infty} p_{ii}^{(n)} = 0$
- **Trvalý nenulový, aperiodický**: $\lim_{n \rightarrow \infty} p_{ii}^{(n)} = \pi_i$
- **Periodický stav**: Limitní pravděpodobnosti oscilují v závislosti na periodě.

Trace: • [b0b01pst](#)